# TAREA # 12 Red neuronal

Natalia Berenice Pérez López

17 de noviembre de 2021

### 1. Objetivo

El objetivo de esta práctica es estudiar de manera sistemática el desempeño de la red neuronal en términos de su puntaje F (F-score en inglés) para los diez dígitos en función de las tres probabilidades asignadas a la generación de los dígitos (ngb), variando a las tres en un experimento factorial adecuado.

### 2. Desarrollo

Para generar el código de esta práctica se realizaron algunas ideas y pruebas iniciales, las cuales se encuentran en mi repositorio en GitHub. Se inició tomando como base el código para la red neuronal de los digitos [2] revisado en clase. Las modificaciones que se le realizaron al código fueron: establecer tres vectores de tres niveles cada uno con las probabilidades de cada color negro, gris y blanco, agregar tres ciclos for para variar dichas probabilidades y otro para hacer 12 réplicas de cada combinación ngb, también se agregó el código para obtener el puntaje F o F-score y un data.frame para almacenar la combinación ngb, el número de réplica y el F-score correspondiente.

A continuación se muestra el fragmeto modificado en el código:

```
df = data.frame()
  probn = c(0.98, 0.65, 0.35) #probabilidades negro
  probg = c(0.95, 0.75, 0.55) #probabilidades gris
  probb = c(0.45,0.10,0.005) #probabilidades blanco
  for (ne in probn){
    for (g in probg){
      for (b in probb){
        for (replica in 1:12){
          modelos <- read.csv("digits.txt", sep=" ", header=FALSE, stringsAsFactors=F)
          modelos[modelos=='n'] <- ne
          modelos[modelos=='g'] <- g
          modelos[modelos=='b'] <- b
13
14
          r <- 5
          c <- 3
16
          dim <- r * c
```

Listing 1: Fragmento del código modificado.

Para el cálculo del F-score se revisó la documentación sugerida por la Dra. Schaeffer [4], en la cual indica que la fórmula para obtener este puntaje es:

$$F - score = 2 \frac{precision * recall}{precision + recall} \tag{1}$$

En seguida se muestra el fragmento del código para obtener el puntaje F:

```
print(contadores)

#Calculo puntaje F-score

precision = diag(contadores) / colSums(contadores[,1:10])

recall = diag(contadores) / rowSums(contadores)

fscore = (2 * precision * recall) / (precision + recall)
```

```
result = c(ne, g, b, replica, fscore)
df = rbind(df, result)
```

Listing 2: Código para obtener el puntaje F.

Utilizando el data. frame obtenido con el código anterior se realizó el diagrama caja-bigote combinado con diagramas de violín para analizar como varía el puntaje F o F-score con las diferentes combinaciones de probabilidades ngb (Ver figura 1). Con apoyo del repositorio de Navarro [1] se cambiaron las etiquetas del eje x en el diagrama.




Figura 1: Puntaje F para cada combinación de probabilidades ngb.

En la figura 1 se puede observar que la combinación de probabilidades con la que se alcanza el mayor puntaje F es la que presenta el máximo valor para negro y gris y el mínimo para blanco. Para analizar si existe una relación entre las combinaciones ngb y el puntaje F obtenido se realizó una prueba estadística. Se eligió realizar la prueba estadística Kruskal Wallis debido a que los datos no presentan normalidad.

En el cuadro 1 se resumen los resultados de la revisión de los supuestos para poder aplicar la prueba estadística. El supuesto outliers se refiere a la cantidad de valores atípicos que existen en los grupos, la normalidad por grupos se obtuvo con la prueba de Shapiro Wilk y la homogeneidad de varianza se obtuvo con la prueba de Levene.

En los resultados se observa que para la normalidad en la mayoría de las combinaciones p es menor a 0,05, por lo tanto no se tiene normalidad.

Cuadro 1: Resultados del los supuestos para aplicar la prueba estadística.

Outliers	47			
Normalidad	0,35/0	55/0,005	5: p =	$1,72 \times 10^{-6}$
por grupo	0.35/0.	55/0,10:	p = 1	$1.81 \times 10^{-4}$
	0.35/0	55/0,45:	p = 1	$1,06 \times 10^{-4}$
	0.35/0.	75/0,005	5: p =	$1,62 \times 10^{-7}$
				$2,05 \times 10^{-6}$
	0.35/0	75/0,45:	p = 2	$2,43 \times 10^{-4}$
	0.35/0.	95/0.00!	p = 1	$2,35 \times 10^{-6}$
	0.35/0.	95/0.10:	p = 4	$4,48 \times 10^{-6}$
	0.35/0.	95/0.45:	p = 2	$2,02 \times 10^{-4}$
	0.65/0.	55/0.00	p = 0	$5,30 \times 10^{-5}$
	0.65/0.	55/0.10:	p = 2	$2,37 \times 10^{-2}$
	0.65/0.	55/0,45:	p = 2	$2,31 \times 10^{-2}$
	0.65/0.	75/0,00	p = 1	$3,42 \times 10^{-3}$
	0.65/0.	75/0.10:	p = 3	$93 \times 10^{-4}$
	0,65/0	75/0,45:	p = 1	$1.16 \times 10^{-5}$
	0,65/0	95/0,00	p = 0	$6,09 \times 10^{-3}$
	0,65/0	95/0,10:	p = 8	$8,46 \times 10^{-4}$
	0,65/0	95/0,45:	p = 7	$7,73 \times 10^{-5}$
	0.98/0.	55/0,008	5: p =	$6,68 \times 10^{-4}$
	0,98/0	55/0,10:	p = 2	$2,58 \times 10^{-1}$
				$1,47 \times 10^{-4}$
	0.98/0.	75/0,00	p = 0	$8,90 \times 10^{-6}$
	0.98/0.	75/0,10:	p = 1	$1,25 \times 10^{-1}$
	0,98/0	75/0,45:	p = 3	$3.07 \times 10^{-3}$
	0.98/0.	95/0,00	5.p = 8	$8,79 \times 10^{-15}$
	0.98/0.	95/0,10:	p=2	$2,38 \times 10^{-6}$
	0.98/0.	95/0,45:	p=1	$,34 \times 10^{-3}$
Homogeneidad		$43 \times 10^{-}$		
de varianza	_ ′			

Al realizar la prueba Kruskal Wallis se obtienen los resultados mostrados en el cuadro 2.

Cuadro 2: Resultados al aplicar la prueba estadística Kruskal Wallis.

Chi cuadrada	Valor de $p$
1603,7	$2.2 \times 10^{-16}$

Hipótesis nula: Las medias son iguales en todos los grupos.

Hipótesis alternativa: Debido a que p < 0.05 se rechaza la hipótesis nula, es decir que si existen diferencias significativas entre las medias de los grupos.

Se entiende entonces que la variación de las probabilidades ngb si tiene un efecto significativo en el puntaje F de cada combinación.

A continuación se muestra el código utilizado para realizar la figura 1 y la prueba estadística Kruskal Wallis:

```
df$Etiquetas <- etiq
10 library(reshape2)
11 df1 <- melt(df,id.vars='Etiquetas', measure.vars=c('0','1','2','3','4','5','6','7','8','9'))
12
png("Figura1.png", width=15, height=15, units="cm", res=1200)
14 gr = ggplot(df1, aes(x= Etiquetas, y= value))+ geom_violin(fill="pink", color="purple", lwd=0.2)
gr + geom_boxplot(width=0.4, fill="cyan", color="black", lwd=0.2, outlier.size = 0.6)+ labs(x="
      Combinacion de probabilidades (n,g,b)", y= "F-score") +
    theme(axis.text.x = element_text(angle = 90, vjust = 0.5, hjust=1))
16
17
  graphics.off()
19 library(tidyverse)
20 library(ggpubr)
21 library(car)
22 library(rstatix)
23 library(rapportools)
24 library(readr)
25 library(gridExtra)
26
27 #PRUEBA ESTADISTICA...
28 #Estadisticas descriptivas
29 df1 %>%
    group_by(Etiquetas) %>%
    get_summary_stats(value, type = "mean_sd")
31
33 #SUPUESTOS PARA ANOVA
34 #1:Outliers
35 df1 %>%
36
    group_by(Etiquetas) %>%
    identify_outliers(value)
37
39 #2:Normalidad por Shapiro
40 tapply(df1$value, df1$Etiquetas, shapiro.test)
41
42 #3: Homogeneidad de varianza con prueba Levene
43 df1 %>%
    levene_test(value~Etiquetas)
45
46 #PRUEBA ESTADISTICA KRUSKAL WALLIS
47 kruskal.test(value ~ Etiquetas, data = df1)
```

Listing 3: Código para graficar y realizar la prueba estadística Kruskal Wallis.

#### 3. Reto 1

Como un primer reto, extiende y entrena la red neuronal para que reconozca además por lo menos doce símbolos ASCII adicionales, aumentando la resolución de las imágenes a 5 x 7 de lo original de 3 x 5 (modificando las plantillas de los dígitos acorde a este cambio).

Para este reto se utilizó como base el código para la red neuronal de los digitos [2] y el código para la generación de imágenes aleatorias de dígitos [3], ambos revisados en clase. Se generó un nuevo archivo de texto .txt llamado digits2 el cual se encuentra en mi repositorio, en este archivo se usan las iniciales de los colores para indicar cuál pixel es cuál yendo por renglones.

A continuación se muestra el fragmeto modificado en el código para el reto 1:

```
modelos <- read.csv("digits2.txt", sep=" ", header=FALSE, stringsAsFactors=F)
modelos[modelos=='n'] <- 0.995
modelos[modelos=='g'] <- 0.92
modelos[modelos=='b'] <- 0.002

r <- 7
c <- 5
dim <- r * c</pre>
```

```
10 tasa <- 0.15
11 tranqui <- 0.99
12
13 tope <- 21
14 digitos <- 0:tope
15 k <- length(digitos)
16 contadores <- matrix(rep(0, k*(k+1)), nrow=k, ncol=(k+1))
17 rownames(contadores) <- 0:tope
18 colnames(contadores) <- c(0:tope, NA)</pre>
```

Listing 4: Fragmento del código modificado para el reto 1.

```
0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 <NA>
0
  3 11
      0 0 0
            0
               0 0 0 0 0 0 0 0 0
                                     0
                                       0
                                          0
                                            0
  0 11
      0 0 0
            0
               0 0 0 0
                      0 0 0
                              0
                                0
                                  0
                                     0
                                        0
                                          0
                                             0
                                               0
                                                      0
  0 0 12 0 0
            0 0 0 0 0
                      0 0 0
      7 1 0
            0 1 1 0 0
  3 0
                      0 0 0
                              0
                                0
                                  1
                                     0
                                        0
                                          0
                                             0
       0 0 0
            1
               0 0 0 0
                      0
                         0
                           7
      0 0 0
            0 0 2 0 0
                      0 0
                           1
                              1
                                1 11
                                        0
                                          0
      1 0 0 0 1 0 2 0
                      0 0 0 0
                                  0
                                        0
                                          0
                                0
                                     0
  0 0 1 0 0 0 11 0 0 0 0 0 0
                                0
                                  0
                                     0
                                        0
8
    2 0 0 0 0 0 0 0 0
                      0 0 0
                             0
                                        0
                                          0
  7
                                0
                                  0
                                     0
                                             0
                                               0
      0 0 0 15
              0 0 0 0
                      0
                        0
                           1
                              1
                                0
                                   0
                                     0
                                        0
10 0 0 1 0 0 0 0 0 2 0 11 0 0
                                        0
                              0
                                0
                                   0
                                     0
                                          0
                                             0 0
                                                      1
11 0 0 0 0 0 0 0 0 0 0 0 0
                                        0
                                          3 0 0
12 0 0 0 0 0 0 0 0 0 0 0 15
                              0 0 0
                                     0
                                       0
                                          0
                                            0 0
13 0 0
      0 0 0 1 0 0 0 0 0 0
                              6 0
                                   0
                                     0
                                        0
                                          0
                                             0 0
                                                  1
                                                      1
14 0
       0 0 0
            0
               0 0 1 0
                      1
                         0
                           0
                              0 17
                                        0
                                          0
15 0 0
      0 0 0 0 0 0 3 0 0 0
                             0 0
                                   7
                                     0
                                        0
                                          0
      0 0 0 0 0 0 0 0
16 2 0
                      0 0 0
                              0 0
                                     3
17 3 11
      0 0 0 0 0 0 1 1 0 0 0
                             0 0 0
                                       0 0 0 0
                                     1
18 0 0
      0 0 0
            0 0 0 0 0
                      0 0
                           0
                              0
                                0
                                  0
                                     0
                                        0 12
                                            0
                                                      0
19 0 0 0 0 0
            0 0 0 0 0
                      0 0
                           0
                              0
                                0
                                  0
                                        0 0 13
20 0 0 0 0 0 0 0 0 0 0 0 0
                                0
                                  Ω
                                     0
                                        0
                                          0 0 0
21 0 8 0 0 0 0 0 0 0 1 0 0 0 0 0 0
```

Listing 5: Matriz de confusión.



Figura 2: Símbolos ASCII.

## 4. Conclusión

Con base en el diagrama caja-bigote combinado con los diagramas de violín y el resultado de la prueba estadística, puedo concluir que el puntaje F o F-score aumenta dependiendo de la combinación de las probabilidades ngb, en la figura 1 se observa que la mejor combinación es n=0.98, g=0.95 y b=0.005, es decir un alto valor para negro y un muy bajo valor de blanco ya que de esta manera se disminuyen las probabilidades de errores al identificar los números, también se puede ver que al disminuir los valores de n y aumentar los valores de b se obtiene un menor puntaje b0 debido a que aumenta la posibilidad de no identificar correctamente los números.

## Referencias

- [1] Eduardo Navarro. tarea12pruebas, 2021. URL https://github.com/eduartilon/Simulacion/blob/main/tarea12/tarea12pruebas/tarea12pruebas.R.
- [2] Elisa Schaeffer. Neural network, 2019. URL https://github.com/satuelisa/Simulation/blob/master/NeuralNetwork/ann.R.
- [3] Elisa Schaeffer. Neural network, 2021. URL https://github.com/satuelisa/Simulation/blob/master/NeuralNetwork/digits.R.
- [4] Boaz Shmueli. Multi-class metrics made simple, part ii: the f1-score, 2019. URL https://towardsdatascience.com/multi-class-metrics-made-simple-part-ii-the-f1-score-ebe8b2c2ca1.